

Reporte de avance — Hackathon 2026

Equipo: Syntax **Integrantes:** Sofía Morato, Joel David Niño y Santiago Muñoz

Fecha de la medición: 2026-10-02

1. Puntaje sobre las preguntas de muestra

Resultado de python scripts/evaluate.py --submission <archivo> --split sample.

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas	14,67	20
Calidad de citación	17,55	20
Abstención calibrada	8,37	10
Total automático sin RAGAS	40,59	50

Observaciones. Preguntas cerradas: 11 de 15 correctas (la referencia es 0,905). Citación: ninguna de las 176 citas emitidas carece de respaldo en los textos recuperados. Abstención: 0 abstenciones; 36 de 43 preguntas respondidas bien.

2. Estado del corpus

Métrica	Valor
Documentos incorporados	588
Fragmentos indexados	113.519
Áreas del banco con cobertura	10 de 10
Áreas del banco sin cobertura	ninguna

Fuentes consultadas. Relatoría de la Corte Constitucional (377); normogramas (CRA, Colpensiones, DIAN; compilación Avance Jurídico) (83); Secretaría del Senado (67); Gestor Normativo de Función Pública (30); Relatoría de la Corte Suprema de Justicia (18); otras (Régimen Legal de Bogotá, ICBF, RedJurista) (8); normograma de la DIAN (3); Comunidad Andina (2).

Documentos por área (un documento puede pertenecer a varias): constitucional 340, laboral 56, de familia 49, penal 45, administrativo 40, comercial y sociedades 36, civil 35, tributario 31, procesal 28, mercados 25.

3. Arquitectura actual

Componente	Elección
Encoder (convierte textos en vectores para comparar significado)	BAAI/bge-m3, modelo multilingüe de código abierto
Decoder (redacta la respuesta)	Qwen3-8B (8.000 millones de parámetros), ejecutado localmente; da siempre la misma respuesta ante la misma pregunta y su salida sigue un formato fijo
Estrategia de recuperación	Combina dos búsquedas: por palabras exactas (útil para números de artículo y siglas) y por significado, y fusiona sus resultados; si la pregunta nombra una norma y un artículo, ese artículo se añade como candidato; se da prioridad a los documentos del área de la pregunta. Se recuperan 10 textos como evidencia y 5 se entregan al decoder; toda cita debe provenir de esos 10 textos
Segmentación del corpus	Cada artículo de una norma es un fragmento (si es muy largo se divide por párrafos); las sentencias se dividen en tramos de unas 350 palabras, sin mezclar secciones
Mecanismo de abstención	Por ahora solo se abstiene cuando no hay respaldo: si no se encuentran textos, si la respuesta del modelo no es válida o si, al quitar las citas que no se pueden comprobar, la respuesta queda vacía. Una regla que decida según la confianza en lo encontrado está en evaluación.

4. Riesgos y limitaciones identificados

1. Tiempo para las 992 preguntas. Deben responderse en unas 6 horas. En la tarjeta gráfica RTX 4090 tardó 11,8 s por pregunta mientras se compartía con otras pruebas, y 4,3 s sin carga; el objetivo es menos de 10 s y falta medirlo en una máquina dedicada. Se fijará una sola máquina y una sola configuración para la corrida final y la verificación en vivo.

2. Búsqueda del artículo exacto y preguntas cerradas. En la muestra, el sistema acierta 11 de 15 de las preguntas cerradas, por debajo de la referencia (0,905), y no siempre encuentra el artículo preciso. La búsqueda da prioridad al área indicada en cada pregunta; si las 992 preguntas no la traen, el puntaje será algo menor. Se probarán mejoras de una en una.

3. Abstención sin calibrar. El sistema casi nunca se abstiene: 7 respuestas incorrectas habrían valido más de haberse abstenido. Se probará una regla sencilla, sin ajustarla en exceso a solo 50 preguntas.

4. Corpus desbalanceado. La mayoría de los documentos son sentencias de la Corte Constitucional, y el derecho de los mercados tiene pocos. Esto puede restar cobertura en las áreas menos representadas; además, las áreas asignadas a 30 documentos adicionales aún no están confirmadas.

5. Entrega final. Faltan empaquetar el corpus, comprobar que el enlace público abre sin sesión iniciada, probar la reproducción desde cero y construir la interfaz.