

Reporte de avance — Hackathon 2026

Equipo: Syntax **Integrantes:** Sofía Morato, Joel David Niño y Santiago Muñoz
Fecha de la medición: 2026-10-02 **Corrida:** e13_lookup (commit 3eeef4)

1. Puntaje sobre las preguntas de muestra

Resultado de `python scripts/evaluate.py --submission <archivo> --split sample`.

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas	14,67	20
Calidad de citación	16,33	20
Abstención calibrada	8,37	10
Total automático sin RAGAS	39,37	50

Observaciones. Cerradas 11/15 (0,733; referencia del baseline 0,905). Citación: recall ponderado 0,816 y 0 citas sin respaldo en 188 emitidas. Abstención: 0 abstenciones; 36 de 43 respondidas bien. Con 50 preguntas, una diferencia de 1–2 aciertos no es significativa.

Referencia adicional con juez RAGAS: *correctness 0,502 (15,06/30)*.

2. Estado del corpus

Métrica	Valor
Documentos incorporados	588
Fragmentos indexados	113.519
Áreas del banco con cobertura	10 de 10
Áreas del banco sin cobertura	ninguna

Fuentes consultadas. Relatoría de la Corte Constitucional (377); normogramas (CRA, Colpensiones, DIAN; compilación Avance Jurídico) (83); Secretaría del Senado (67); Gestor Normativo de Función Pública (30); Relatoría de la Corte Suprema de Justicia (18); otras (Régimen Legal de Bogotá, ICBF, RedJurista) (8); normograma de la DIAN (3); Comunidad Andina (2).

Documentos por área (un documento puede tener varias): constitucional 340, laboral 56, de familia 49, penal 45, administrativo 40, comercial y sociedades 36, civil 35, tributario 31, procesal 28, mercados 25. El corpus tiene desbalance hacia constitucional (sentencias de la Corte); las áreas de 30 documentos adicionales son provisionales.

3. Arquitectura actual

Componente	Elección
Encoder	BAAI/bge-m3 (fp32, FAISS IndexFlatIP, vectores normalizados)
Decoder	Qwen3-8B, cuantización Q8_0 con llama.cpp; temperature=0, seed=0, salida restringida por JSON Schema
Estrategia de recuperación	Híbrida: BM25 (bm25s) + denso, fusión RRF (k=60), más búsqueda por referencia explícita (norma/artículo detectados con citations.py) como candidato extra; top-10 como evidencia, 5 pasajes al decoder; citas validadas contra el top-10
Segmentación del corpus	seg-v1: un artículo = un fragmento (≤350 palabras, partido por párrafos); sentencias en ventanas de ~350 palabras por sección
Mecanismo de abstención	Validación de citas contra el top-10; si quedan campos vacíos tras regenerar, se abstiene. Regla por señales (score, margen, acuerdo BM25/denso) en evaluación.

4. Riesgos identificados

- Tiempo de las 992 preguntas (≈6 h).** 4,3 s/pregunta en la RTX 4090 cumple el objetivo (<10 s), pero un Mac M1 tarda ~145 s: se congela una sola máquina y configuración para la corrida final y la verificación en vivo.
- Recuperación a nivel de artículo y exactitud en cerradas.** En muestra, `art_hit@10` ≈ 0,4–0,5 y cerradas 0,733 frente a la referencia 0,905. Se prueban reranker, ajuste de la búsqueda por referencia explícita y `generation_k`, un cambio por experimento.
- Abstención sin calibrar.** 7 respuestas incorrectas que valdrían 0,5 si se abstuviera; se evalúa una regla simple por formato, sin sobreajustar a 50 preguntas.
- Entrega del corpus y reproducibilidad.** Falta el empaquetado, el enlace público verificado en ventana privada y la prueba en contenedor limpio (reproducir.py); la interfaz sigue pendiente.