

Reporte de avance — Hackathon 2026

Equipo: Syntax **Integrantes:** Sofía Morato, Joel David Niño y Santiago Muñoz

Fecha de la medición: 2026-10-02 **Corrida:** e16_area200 (commit 26932e7)

1. Puntaje sobre las preguntas de muestra

Resultado de `python scripts/evaluate.py --submission <archivo> --split sample`.

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas	14,67	20
Calidad de citación	17,55	20
Abstención calibrada	8,37	10
Total automático sin RAGAS	40,59	50

Observaciones. Cerradas 11/15 (0,733; referencia del baseline 0,905). Citación: recall ponderado 0,878 y 0 citas sin respaldo en 176 emitidas. Abstención: 0 abstenciones; 36 de 43 respondidas bien. Con 50 preguntas, una diferencia de 1–2 aciertos no es significativa.

2. Estado del corpus

Métrica	Valor
Documentos incorporados	588
Fragmentos indexados	113.519
Áreas del banco con cobertura	10 de 10
Áreas del banco sin cobertura	ninguna

Fuentes consultadas. Relatoría de la Corte Constitucional (377); normogramas (CRA, Colpensiones, DIAN; compilación Avance Jurídico) (83); Secretaría del Senado (67); Gestor Normativo de Función Pública (30); Relatoría de la Corte Suprema de Justicia (18); otras (Régimen Legal de Bogotá, ICBF, RedJurista) (8); normograma de la DIAN (3); Comunidad Andina (2).

Documentos por área (un documento puede tener varias): constitucional 340, laboral 56, de familia 49, penal 45, administrativo 40, comercial y sociedades 36, civil 35, tributario 31, procesal 28, mercados 25. El corpus tiene desbalance hacia constitucional (sentencias de la Corte); las áreas de 30 documentos adicionales son provisionales.

3. Arquitectura actual

Componente	Elección
Encoder	BAAI/bge-m3 (fp32, FAISS IndexFlatIP, vectores normalizados)
Decoder	Qwen3-8B, cuantización Q8_0 con llama.cpp; temperature=0, seed=0, salida restringida por JSON Schema
Estrategia de recuperación	Híbrida: BM25 (bm25s) + denso, fusión RRF (k=60), más búsqueda por referencia explícita (norma/artículo detectados con citations.py) como candidato extra; prioridad por área del banco (factor 2,0, reordena sin filtrar); top-10 como evidencia, 5 pasajes al decoder; citas validadas contra el top-10
Segmentación del corpus	seg-v1: un artículo = un fragmento (≤ 350 palabras, partido por párrafos); sentencias en ventanas de ~ 350 palabras por sección
Mecanismo de abstención	Validación de citas contra el top-10; si quedan campos vacíos tras regenerar, se abstiene. Regla por señales (score, margen, acuerdo BM25/denso) en evaluación.

4. Riesgos identificados

1. Tiempo de las 992 preguntas (≈ 6 h). 11,8 s/pregunta con la GPU compartida con otros experimentos (4,3 s sin carga, e14); el objetivo es <10 s y falta medirlo en máquina dedicada. Se congela una sola máquina y configuración para la corrida final y la verificación en vivo; un Mac M1 tarda ~ 145 s por pregunta.

2. Recuperación a nivel de artículo, cerradas y dependencia del campo área. En muestra, $\text{art_hit@10} \approx 0,4\text{--}0,6$ y cerradas 0,733 frente a la referencia 0,905. La prioridad por área usa el campo «area» de la pregunta (presente en la muestra); si las 992 no lo traen, el puntaje será el de la recuperación sin ese refuerzo. Se prueban reranker y generation_k, un cambio por experimento.

3. Abstención sin calibrar. 7 respuestas incorrectas que valdrían 0,5 si se abstuviera; se evalúa una regla simple por formato, sin sobreajustar a 50 preguntas.

4. Entrega del corpus y reproducibilidad. Falta el empaquetado, el enlace público verificado en ventana privada y la prueba en contenedor limpio (reproducir.py); la interfaz sigue pendiente.